Türk İşaret Dili Tabanlı Gerçek Zamanlı El Hareketi Tanıma ve Çeviri Sistemi

Bitirme Projesi Ara Raporu

Mustafa Göktepe Ahmet Çelik Mustafa Küpeli

Danışman: Ar. Gör. Hayri Öztürk

Erciyes Üniversitesi, Bilgisayar Mühendisliği

Kasım 2026

Neyi çözmek istiyoruz?

- İşaret dili bilmeyen biriyle iletişim çoğu zaman yazıya ya da bir yakının tercümanlığına kalıyor.
- Hastane, banka, resmî daire gibi yerlerde bu hem zaman kaybı hem mahremiyet sorunu.

Hedefimiz

- Telefon kamerasıyla TİD işaretini tanıyıp yazıya çeviren bir uygulama
- Ek donanım yok: eldiven ya da derinlik kamerası kullanmıyoruz
- İnternet yok: model telefonun içinde, görüntü cihazdan çıkmıyor
- Kapsam kelime düzeyi (226 işaret); cümle çevirisi kapsam dışı

Ekip ve iş bölümü

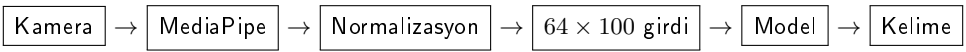
Kim	Sorumluluk	Bu dönemde yapılan
Mustafa Küpeli	Veri hazırlığı, veri hattı, normalizasyon	Veri setinin doğrulanması, nokta çıkarımı
Mustafa Göktepe	Model, eğitim, optimizasyon	İki modelin eğitimi, karşılaştırma, hata analizi
Ahmet Çelik	Mobil uygulama, arayüz, donanım entegrasyonu	Kamera ve çıkarım hattı, Flutter arayüzü

- Ortak depo GitHub'da; herkes kendi dalında çalışıp birleştirme isteği açıyor.
- Deney sonuçları `experiments/` klasöründe kayıtlı, tekrar üretilebiliyor.

Neleri kullandık?

İş	Araç
Veri seti	AUTSL (226 işaret, 43 işaretçi, 36.302 video)
El ve gövde noktaları	Google MediaPipe Tasks (hand landmarker, pose landmarker lite)
Model eğitimi	Python, PyTorch (Apple M4 ve RTX 3050 üzerinde)
Ölçüm ve grafikler	scikit-learn, matplotlib
Telefona aktarım	Keras üzerinden LiteRT (`.tflite`), int8 nicemleme
Kamera ve çıkarım	Kotlin, CameraX
Arayüz	Flutter
Sürüm takibi ve rapor	Git, GitHub, LaTeX

Sistemi nasıl kurduk?



- Modele video karesi değil, iskelet koordinatları veriyoruz. Model küçük kalıyor, ham görüntü işlenmiyor.
- Nokta çıkarımını eğitimde de telefonda da aynı MediaPipe API'siyle yaptık; iki taraf arasında nokta sırası ve normalizasyon farkı olmasın diye.
- Eğitim bilgisayarda, çıkarım tamamen telefonda.

Veriyi nasıl hazırladık?

Veri hattı: Mustafa Küpeli

Veri seti kontrolü

- AUTSL'nin resmî bölmelerini kullandık: eğitim, doğrulama, test
- Bölmelerde aynı işaretçi yok; bunu ayrıca kontrol ettik
- 11 video yarım inmişti, açılmadı; listeleyip dışarıda bıraktık
- Kalan: 28.132 eğitim, 4.418 doğrulama, 3.741 test

Nokta çıkarımı

- Her karede iki el $\times$ 21 nokta, gövdeden 7 nokta
- El bulunma oranı: sol yüzde 82, sağ yüzde 86
- Omuz ortasına öteledik, omuz genişliğine böldük: uzaklık ve boy etkilemiyor
- Kare başına 100 sayı, her video 64 kare

Hangi modelleri kurduk?

Model: Mustafa Göktepe

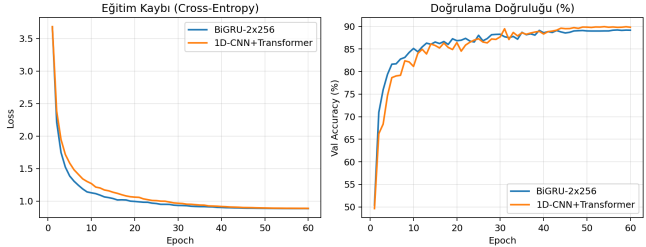
	BiGRU-2x256	**1B-CNN + Transformer**
Yapı	2 katman, iki yönlü GRU	3 evrişim + 2 Transformer katmanı
Zaman bilgisi	Kare kare, ileri ve geri	Yerel evrişim, sonra dikkat
Dizi uzunluğu	64	64 $\rightarrow$ 32 (stride 2)
Parametre	2.114.018	1.473.634

- Önce BiGRU'yu temel model olarak kurduk; telefonda çalışan sürüm bu.
- Tez önerisinde söz verdiğimiz karşılaştırma için ikinci modeli ekledik.
- İkisinde de çıkışta zaman ortalaması alıyoruz; işaretin hangi karede bittiği belli olmadığı için.

Nasıl eğittik?

Model: Mustafa Göktepe

- İki modele aynı ayarları verdik
- 60 epoch, AdamW, lr 2×10^{-3}
- Kosinüs azaltım, batch 128
- Kareleri seyrelterek telefonun düşük FPS'ine benzettik
- Kırpma, döndürme, ölçek artırması
- Test kümesine eğitim bitince bir kez baktık



Ne elde ettik?

Model: Mustafa Göktepe

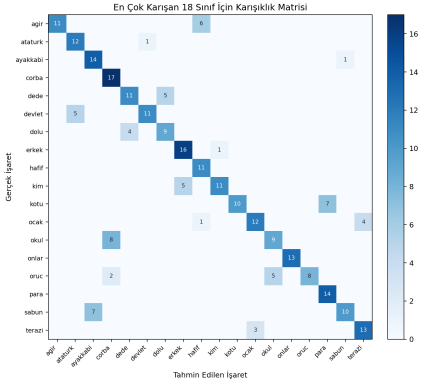
Model	Parametre	Doğrulama (%)	Test (%)	Macro F1 (%)
BiGRU-2x256	2.114.018	89,23	88,24	88,09
1B-CNN + Transformer	1.473.634	**89,97**	**88,83**	**88,61**

Üç tohum (0, 1, 2)	Test ort. ± ss (%)	Doğrulama ort. (%)
BiGRU-2x256	87,98 ± 0,23	89,38
1B-CNN + Transformer	**89,42 ± 0,52**	**90,37**

- Tez önerisindeki yüzde 85 hedefini iki modelde de geçtik.
- Küçük model üç tohumun üçünde de önde çıktı.

Model nerede yanılıyor?

Model: Mustafa Göktepe



Gerçek	Tahmin	Hata
okul	çorba	8 / 17
kötü	para	7 / 17
sabun	ayakkabı	7 / 17
ağır	hafif	6 / 17

- Test kümesindeki 3.741 örnek için karışıklık matrisi çıkardık.
- Hatalar rastgele değil: el formu ve konumu aynı olan işaretler karışıyor.
- Güven eşiğini 0,6 seçtik: örneklerin yüzde 75'i kabul ediliyor, bunlarda doğruluk yüzde 96,8.

Modeli telefona nasıl taşıdık?



- Dosya boyutu 9,43 MB'tan 3,19 MB'a indi; hedefimiz 10 MB'ın altıydı.
- int8 sürümün test doğruluğu yüzde 88,0; kayıp yok.
- Aynı 200 test örneğini hem Python'da hem telefonda çalıştırdık: tahminlerin yüzde 99,5'i aynı.

Mobil uygulamayı nasıl kurduk?

Mobil: Ahmet Çelik

Yapı

- Kamera, MediaPipe ve LiteRT Kotlin tarafında (CameraX)
- Ekranlar ve durum yönetimi Flutter'da
- İki taraf olay kanallarıyla (event channel) konuşuyor
- Model dosyası uygulamanın içinde, çevrimdışı çalışıyor

Ölçümler

- Model çıkarımı ortalama 48 ms (Redmi Note 10 Pro)
- Uçtan uca hız yaklaşık 9 FPS; hedef 15 FPS
- Darboğaz model değil, kare başına çalışan iki MediaPipe modeli

Henüz çözemediklerimiz

- **Canlı kamerada güven düşük.** Kayıtlı test verisinde yüzde 88–89 alırken canlı denemede tahmin güveni yüzde 3–20 aralığına düşüyor.
- Neden henüz ayrışmadı: MediaPipe'ın canlı görüntüdeki nokta kalitesi, ön işleme farkı ya da segmentleme kuralları olabilir.
- Planımız: aynı videoyu hem Python'da hem telefonda çıkarıp noktaları tek tek karşılaştırmak.

- **Hız hedefin altında.** 9 FPS'teyiz, hedef 15 FPS.

Takvim ve sıradaki işler

Kilometre taşı	Tarih	Durum
M0: depo, erişim, veri doğrulama	29 Ekim	Tamamlandı
M1: nokta çıkarımı, iki modelin eğitimi, LiteRT	7 Kasım	Tamamlandı
M2: ara rapor, karşılaştırma ve hata analizi	20 Kasım	Devam ediyor
M3: üç tohum analizi, nihai model	4 Aralık	Devam ediyor
M4: üç ekranlı uygulama, uçak modu testleri	11 Aralık	Planlandı
M5: gönüllü testleri, performans ölçümleri	18 Aralık	Planlandı
M6: tez teslimi	1 Ocak	Planlandı

- 1B-CNN + Transformer'ı da LiteRT int8'e aktarıp telefonda BiGRU ile karşılaştıracağız.
- En az 30 işaret ve farklı kullanıcılarla gönüllü test protokolü hazırlayacağız.